Обзор литературы и формализация нейросимвольного отбора кандидатов

(Разделы 2 и 3.1)

2 Обзор литературы и теоретических предпосылок (Related Work)

Большие языковые модели (LLM) хорошо справляются с анализом неструктурированных запросов на естественном языке и выделением пользовательских предпочтений. Однако сами по себе генеративные модели ненадёжны в задачах многоэтапного комбинаторного планирования с жёсткими ограничениями [1]: они часто нарушают структуру плана, допускают накладки в расписании и ошибаются в простых арифметических расчётах [2]. Даже использование агентных подходов с пошаговыми рассуждениями (например, ReAct [3]) не гарантирует составление непрерывного расписания, соблюдение ограничений по вместимости и точный подсчёт итогового бюджета [2].

Параллельно с развитием языковых моделей способы хранения данных в сложных предметных областях перешли от реляционных таблиц к графам знаний (Knowledge Graphs), графам свойств (labeled property graphs) и иерархическим метаграфам, в которых удобно описывать вложенный контекст и многошаговые (multi-hop) связи между объектами. Чтобы избавиться от галлюцинаций чисто нейросетевой генерации, в современных работах применяются гибридные нейросимвольные архитектуры, объединяющие LLM с внешними верификаторами [1] и графовыми структурами [4, 5]. Опираясь на этот подход, мы делим задачу на отдельные этапы: языковая модель и модель эмбеддингов отвечают только за разбор текста запроса и векторный поиск по смыслу, проверка жёстких условий выносится в формальный графовый верификатор, а итоговая сортировка подходящих вариантов выполняется быстрыми алгоритмами ранжирования (Learning-to-Rank, LTR).

3 Методология

3.1 Декомпозиция задачи и первичный отбор кандидатов

Следуя описанному подходу, на предварительном шаге языковая модель используется только для извлечения параметров из текста запроса, не выполняя саму проверку ограничений. На вход подаётся неструктурированный пользовательский запрос q, который нейросетевой парсер преобразует в кортеж $\langle \mathbf{e}(q), C_u \rangle$. Здесь $\mathbf{e}(q) \in \mathbb{R}^d$ — d-мерный вектор (эмбеддинг), передающий общую семантику и неформальные пожелания пользователя, а C_u — набор явно заданных жёстких ограничений. В состав C_u входят список исключённых пользователем объектов H_{excl} и минимально допустимые пороги $\{c_{u,r}\}$ для обязательных характеристик из множества M_{req}.

Поскольку прямой комбинаторный поиск на полном графе приводит к экспоненциальному росту пространства перебора [2, 5], первичный отбор кандидатов проводится в два шага: на уровне отдельных узлов и на уровне макрокластеров (см. рис. 1).

Сначала на микроуровне (этап I) целевые узлы $h \in V_{\text{serv}}$ проходят жёсткую булеву фильтрацию по списку исключений H_{excl} и обязательным бинарным или числовым признакам M_{req}:

$$\Phi_{\text{filter}}(h, C_u) = \mathbb{I}(h \notin H_{\text{excl}}) \cdot \prod_{r \in M_{\text{req}}} \mathbb{I}(\text{attr}_r(h) \geq c_{u,r}), \tag{1}$$

где $\mathbb{I}(\cdot) \in \{0, 1\}$ — индикаторная функция, $\text{attr}_r(h)$ возвращает значение признака r у узла h, а $c_{u,r} \in C_u$ задаёт минимальный порог из запроса. Функция Φ_{filter} равна 1 только для тех объектов, которые не попали в список исключений и одновременно проходят по всем базовым требованиям пользователя.

Затем на макроуровне (этап II) агрегированные кластеры d_j, которым сопоставлены векторы $\mathbf{e}(d_j) \in \mathbb{R}^d$, оцениваются по смысловой близости к запросу через косинусное сходство:

$$S_{\text{vec}}(q, d_j) = \frac{\mathbf{e}(q) \cdot \mathbf{e}(d_j)}{\|\mathbf{e}(q)\|_2 \, \|\mathbf{e}(d_j)\|_2}, \tag{2}$$

где $\| \cdot \|_2$ — евклидова (L_2) норма вектора, после чего отбираются кластеры, преодолевшие заданный порог близости $S_{\text{vec}}(q, d_j) \geq \tau_{\text{vec}}$.

Последовательное применение формул (1) и (2) позволяет быстро отбросить неподходящие узлы и кластеры ещё до запуска ресурсоёмких графовых алгоритмов. В результате на этап формальной графовой верификации (этап III) и финального ранжирования предпочтений алгоритмами Learning-to-Rank (этап IV) передаётся уже компактный подграф допустимых кандидатов.



Рис. 1: Общая схема пайплайна обработки запроса: от первичной фильтрации до финального ранжирования кандидатов (этапы I–IV).

Список литературы

[1] Valmeekam K., Marquez M., Sreedharan S., Kambhampati S. On the Planning Abilities of Large Language Models — A Critical Investigation // Advances in Neural Information Processing Systems (NeurIPS). 2023. Vol. 36. P. 75993–76005.

[2] Xie J., Zhang K., Chen J., Zhu T., Lou R., Tian Y., Xiao Y., Su Y. TravelPlanner: A Benchmark for Real-World Planning with Language Agents // Proceedings of the 41st International Conference on Machine Learning (ICML). PMLR, 2024. Vol. 235. P. 54590–54613.

[3] Yao S., Zhao J., Yu D., Du N., Shafran I., Narasimhan K., Cao Y. ReAct: Synergizing Reasoning and Acting in Language Models // International Conference on Learning Representations (ICLR). 2023.

[4] Pan S., Luo L., Wang Y., Chen C., Wang J., Wu X. Unifying Large Language Models and Knowledge Graphs: A Roadmap // IEEE Transactions on Knowledge and Data Engineering (TKDE). 2024. Vol. 36, No. 7. P. 3580–3599. DOI: 10.1109/TKDE.2024.3352100.

[5] Sun J., Xu C., Tang L., Wang S., Lin C., Gong Y., Ni L. M., Shum H.-Y., Guo J. Think-on-Graph: Deep and Responsible Reasoning of Large Language Model on Knowledge Graph // International Conference on Learning Representations (ICLR). 2024.